


인공지능 비전 기반 RT 필름 결합 자동 판독 기술

이지정의 필름쇼



CONTENTS

01 배경

02 목표 설정

03 이미지 전처리

04 모델 선정

05 용접 부위 추출 모델 구현 및 결과

06 불량 탐지 모델 구현 및 결과

07 서버 구현


08 결론 및 향후 연구 과제




배경 - RT 필름

- RT필름 : Radiography Test Film, 방사선 비파괴 검사로 얻어진 사진
- 필름에 도달한 투과 방사선 양에 따라 필름의 흑화도가 차이난다.
- 두꺼울수록 하얗게 보이고 대부분의 불량(기포, 갈라짐 등등)은 검게 보인다.
- 일부 결함은 용접 부위보다 밝은 경우도 있다.(ex. 용접재료가 과하게 충전 된 경우)

Radioactive
source



배경





용접부는 흰색으로,
용접부 내 결함(기포)은 검은색으로
표시되는 것을 볼 수 있다





배경 – RT 필름

- 본 과제에서 사용하는 RT필름은 조선소에서 배를 제작할 때 파이프의 용접 부위를 찍은 것이다
- 이를 통해 파이프 용접 부위의 결함을 확인할 수 있다




Radioactive
source




Film




배경 - RT 필름



소형관



중형관



대형관

이미지 데이터 수


기본	대형관	중형관	소형관	총합
정상	106	101	42	249
결함	109	98	7	214
총합	215	199	49	463



배경 - RT 필름

결함의 종류

1. CR 가장 위험




2. EP




3. IP(LP)



4. LF



5. PO 최다 빈도




6. RC




7. SL



8. TI



9. UC



번호	결함	빈도
1	균열	5위
2	용입 과다	3위
3	용입 부족	4위
4	융합 부족	2위
5	기공	1위
6	루트 오목	3위
7	슬래그 라인	4위
8	텅스텐 혼입	4위
9	언더 컷	4위



목표 설정



- 연구의 목표는 제목처럼 인공지능 비전 기술을 활용해 RT 필름에서 확인 할 수 있는 결함을 자동으로 판독하는 것이다
 - 빠른 판독, 정확한 판독을 위해
- 지도 학습, 결함을 직접 학습하는 방법과 비지도 학습, 정상 이미지의 패턴을 학습한 후 결함을 탐지하는 방법 두 가지가 있다.
- 자료의 수가 적고, 각 케이스 별 결함이 적어 목표를 비지도 학습을 위한 용접 부위를 추출해 내고, 이 데이터 세트를 활용하여 불량 탐지를 시도한다.

이미지 데이터 수

기본	대형관	중형관	소형관	총합
정상	106	101	42	249
결함	109	98	7	214
총합	215	199	49	463

이미지 전처리


- 효과적인 모델 제작을 위해 이미지 전처리를 시도했다
- 이미지 전처리만을 통해 용접 부위를 추출해 낼 수 있다면 배경을 잘라내고 결함 탐지를 쉽게 시도할 수 있을 거라 기대했다
- 이미지를 잘라 불필요한 부분을 제거하고, 이미지의 채널을 줄여 연산을 줄이기 위해 RGB 채널을 가진 이미지를 **흑백으로 변환**했다



이미지 전처리



원본 이미지





크기 조정 후 흑백(GrayScale)화 한 이미지





이미지 전처리

- 확실하게 용접 부위와 배경을 구분하기 위해 Thershold를 사용했다



이미지 전처리

- 노이즈를 제거하기 위해 Erosion을 사용했다





용접 부위 외의 하얀 부분이 대부분 사라진 것을 볼 수 있다



이미지 전처리

- Eroding을 통해 손실된 용접 부위를
Dilation을 사용해 보정해주었다




줄어든 용접 부위가 다시 늘어난 것을 볼 수 있다



이미지 전처리


- contours 함수, 일정한 값을 가지는 점들을 연결하여 곡선을 그리는 함수를 사용해 전처리 된 이미지에 영역을 그리고 원본 이미지에 다시 표시했다.



이미지 전처리 - 문제점

- 용접 부위가 일정한 위치에 있지 않았다.

용접 부위 포함




용접 부위 미포함



이미지 전처리 - 문제점

- 대부분 용접부는 흰색, 배경은 회색 계열로 되어있지만, 여러 장의 이미지를 하나로 합친 것이라 배경의 색에 흰색이 섞여 있거나 해서 명확하게 구분이 되지 않는 경우도 있다



배경에 흰색이 섞여 있는 이미지


전처리 한 결과가 좋지 않다.

Dice coefficient : 0.2153




추가 설명 - Dice Coefficient

Dice Coefficient




$$Dice = \frac{2|A \cap B|}{|A| + |B|} = \frac{2TP}{(TP + FP) + (TP + FN)} = \frac{2TP}{2TP + FP + FN}$$


Dice=1.00



Dice=0.69




Dice=0.40



- Dice Coefficient을 이용하여 평가한다
- 0.7 이상이면 우수한 segmentation을 했다고 평가한다

이미지 전처리 - 문제점

- 대형관은 평균 Dice coefficient 0.7993로 준수하긴 하나, 앞서 나온 예시처럼 추출이 잘 안된 경우도 존재한다.
- 중형, 소형관은 Dice coefficient가 0.1 미만으로 나와 추출이 되지 않았다.



중형관 예시
Dice coefficient
: 0.0108



모델 선정 - 용접 부위 추출

CNN

- 이미지 처리에 특화되어있다
- 입력 이미지를 여러 계층으로 나누어, 합성곱과 풀링 계층을 통해 정보를 추출하고 이를 결합하여 결과를 도출한다

ResNet

- 그래디언트 소실 문제를 해결하기 위해 개발된 모델이다
- 많은 계층을 사용함에도 오차가 크게 나지 않을 수 있어 더 나은 성능을 보여준다

• Unet

- Contracting Path(인코더)와 Expanding Path(디코더)로 구성된다
- 인코더에서는 이미지를 다운 샘플링하여 추상화된 특성을 추출하고, 디코더에서는 업 샘플링하여 예측을 수행한다

모델 선정 – 용접 부위 결함 판독

OCSVM(One Class Support Vector Machine)

- 머신 러닝 방식
- 데이터들을 N차원의 좌표축으로 뿌린 후, 원점과의 거리를 기준으로 판독

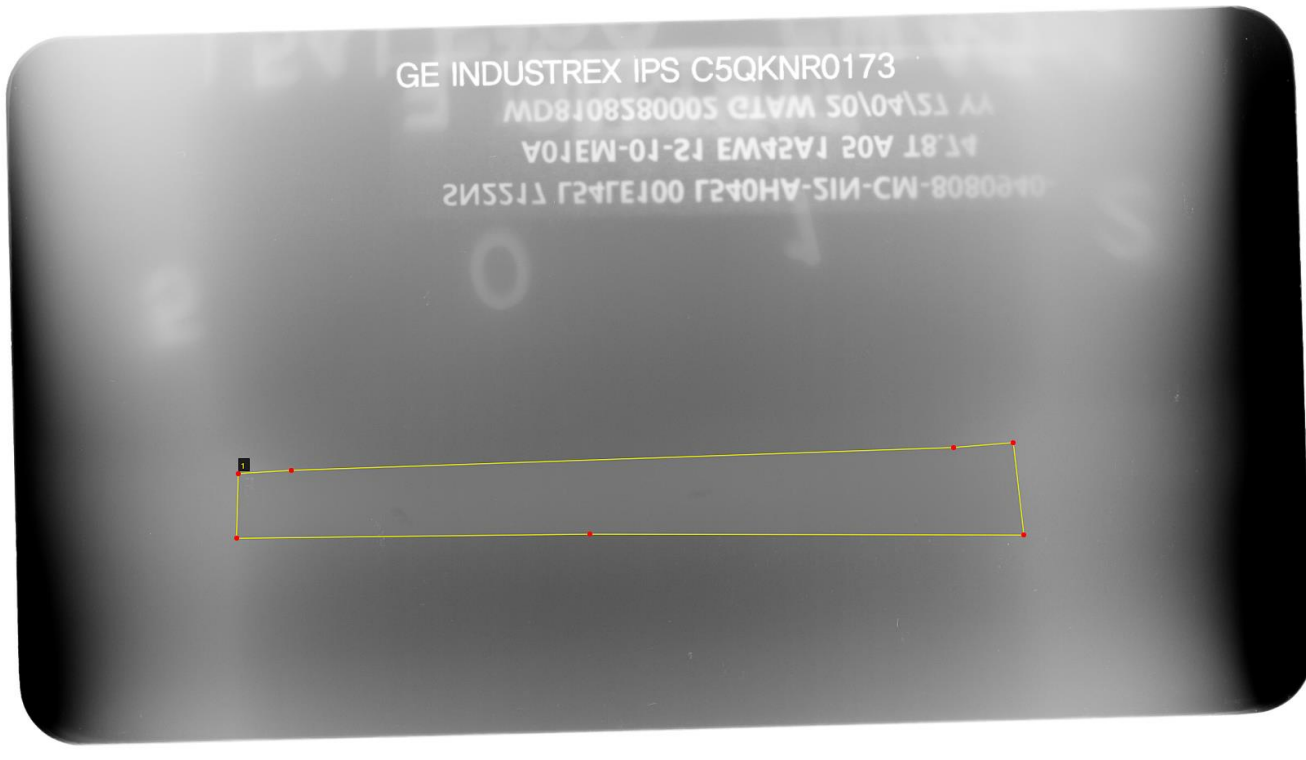
AutoEncoder

- 이미지를 저차원으로 인코딩후 다시 고차원으로 디코딩
- 이미지를 재구축 할때 생기는 오차를 사용해 이상이미지를 판독

Cut Paste(+ResNet)

- 정상 이미지를 이용해 이상 이미지를 생성한다.
- ResNet을 사용하여 정상 이미지와 이상 이미지를 학습
- 가우시안 밀도 추정법을 사용하여 판독


용접 부위 추출 모델 구현 1차 - 라벨링



- VCG Image annotater를 사용하여 이미지 라벨링을 진행하였다.
- 용접 부위만 포함하기 위해 polygon 형태로 이미지 라벨링을 하였다.



용접 부위 추출 모델 1차 - 결과



중형관 예시 1 Dice coefficient : 0.4315

중형관 예시 2 Dice coefficient : 0.8545

중형관 test 결과
평균 Dice coefficient : 0.7705




용접 부위 추출 모델 구현 2차 - 라벨링



- 이미지를 자르고 라벨링을 진행한다.
- 너무 많은 배경을 포함하지 않기 위해, 또한, 데이터 증강을 위해 **이미지를 잘라서 학습**하였다.
- 용접 부위 위아래 2-3mm 여유를 두고 직사각형 형태로 라벨링하였다.(선행 연구 참조)




용접 부위 추출 모델 2차 - 결과




대형관 예시 1

Dice coefficient : 0.9703



중형관 예시 2

Dice coefficient : 0.9175



소형관 예시 3

Dice coefficient : 0.8558

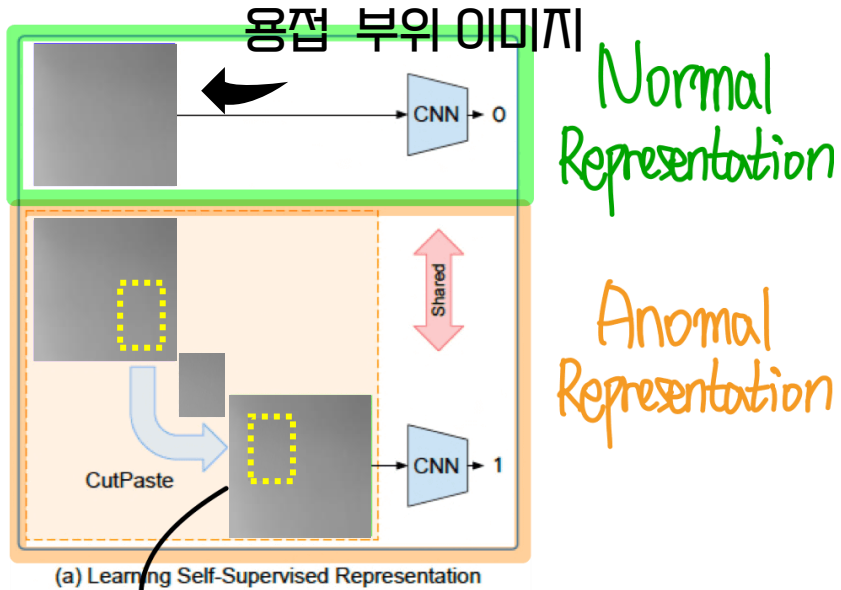
테스트 데이터 종류	대형관	중형관	소형관
평균	0.7981	0.8797	0.7902

중형관 1차 학습(0.7705) 보다 성능이 올라간 것을 확인 할 수 있다



용접 부위 추출 모델 구현 및 결과

Train Process



만들어낸 Anomal Image

Cut Paste를 사용하여 마스킹 생성

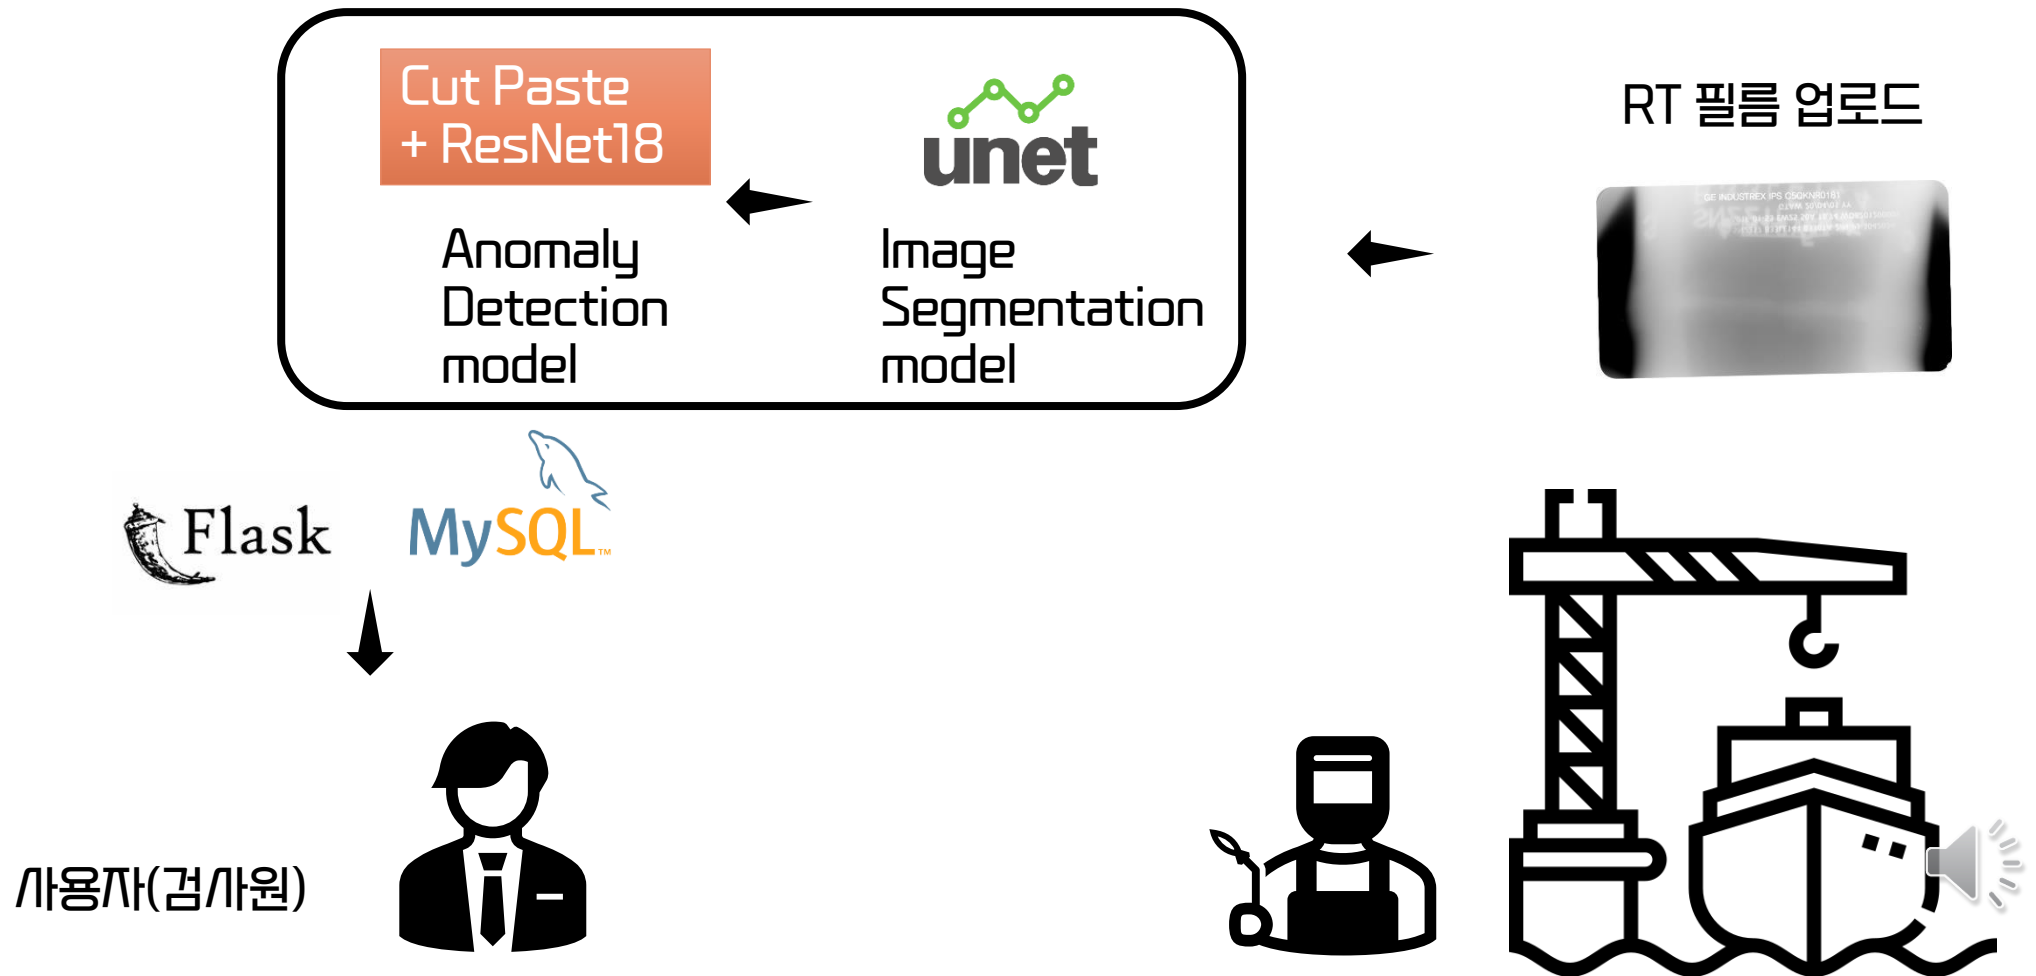
ResNet 18을 사용하여 학습

using density estimation GaussianDensityTorch
small AUC: 0.6727272727272727

테스트 이미지 확인 결과 67.27%의 정확성을 보여줌




서버 구현



결론 및 향후 연구과제

테스트 데이터 종류별 Dice coefficient 평균

테스트 데이터 종류	대형관	중형관	소형관
평균	0.7981	0.8797	0.7902

- 목표인 UNet 모델을 사용하여 **용접 부위를 검출**하는 데 성공했다. (Dice coefficient 0.7 이상)
- **개버**에 이미지를 업로드하고, 학습된 모델이 **추출한 용접 부위에서 결함 판독**을 하는 것을 확인했다.
(약 70% 정확도)
- 이후의 연구를 통해 데이터 보강, 모델 파라미터 조정 등으로 **용접 부위 추출 성능과 용접 부위 결함 탐지율을**  끌어올린다.